

Data Science adalah bidang interdisipliner yang menggabungkan statistik, matematika, pemrograman, dan domain knowledge untuk mengekstrak wawasan dan pengetahuan dari data. Data Scientist bertugas mengumpulkan, membersihkan, menganalisis, dan memvisualisasikan data untuk mendukung pengambilan keputusan bisnis.

Proses Data Science mengikuti siklus yang disebut CRISP-DM (Cross-Industry Standard Process for Data Mining): Business Understanding (memahami tujuan bisnis), Data Understanding (eksplorasi data awal), Data Preparation (pembersihan dan transformasi data), Modeling (membangun model), Evaluation (mengevaluasi performa model), dan Deployment (penerapan model ke produksi).

Eksploratory Data Analysis (EDA) adalah langkah awal dalam analisis data untuk memahami struktur, distribusi, dan hubungan antar variabel. EDA meliputi perhitungan statistik deskriptif (mean, median, modus, standar deviasi), visualisasi distribusi dengan histogram dan boxplot, analisis korelasi dengan heatmap, dan deteksi outlier dengan IQR atau z-score.

Feature Engineering adalah proses membuat fitur baru atau mentransformasi fitur yang ada untuk meningkatkan performa model machine learning.

Teknik umum meliputi encoding variabel kategorikal (one-hot encoding, label encoding), normalisasi dan standarisasi data numerik, penanganan missing values (imputasi rata-rata, median, atau KNN imputer), dan pembuatan fitur interaksi.

Model machine learning dibagi menjadi dua kategori utama: supervised learning (pembelajaran terawasi) dan unsupervised learning (pembelajaran tidak terawasi). Supervised learning mencakup regresi (untuk prediksi nilai kontinu) dan klasifikasi (untuk prediksi kategori). Algoritma populer meliputi Linear Regression, Logistic Regression, Decision Tree, Random Forest, Gradient Boosting, SVM, dan Neural Network.

Evaluasi model menggunakan metrik yang berbeda tergantung jenis masalah. Untuk klasifikasi: Accuracy, Precision, Recall, F1-Score, dan AUC-ROC. Untuk regresi: MSE, RMSE, MAE, dan R-squared. Cross-validation digunakan untuk mendapatkan estimasi performa model yang lebih robust dengan membagi data ke dalam beberapa fold.

Bias-variance tradeoff adalah konsep fundamental dalam machine learning. Model dengan variance tinggi cenderung overfit (terlalu hafal data training). Model dengan bias tinggi cenderung underfit (terlalu simpel). Regularisasi (L1/Lasso dan L2/Ridge) digunakan untuk mengurangi overfitting. Teknik lain termasuk dropout untuk neural network dan pruning untuk decision tree.