

Retrieval-Augmented Generation (RAG) adalah teknik dalam Natural Language Processing (NLP) yang menggabungkan sistem pencarian informasi (retrieval) dengan model bahasa generatif (generation)

RAG bekerja dengan cara mengambil konteks relevan dari basis data dokumen sebelum menghasilkan jawaban, sehingga jawaban yang dihasilkan lebih akurat dan berbasis pada fakta yang ada. Komponen utama RAG adalah: (1) Retriever, yaitu sistem yang mencari dokumen atau potongan teks yang relevan dengan pertanyaan pengguna; (2) Generator, yaitu model bahasa besar (LLM) yang menggunakan konteks yang diambil untuk menghasilkan jawaban; dan (3) Knowledge Base, yaitu basis data dokumen yang diindeks menggunakan embedding vektor. Proses kerja RAG dimulai dengan encoding pertanyaan pengguna menjadi vektor embedding. Selanjutnya, sistem mencari chunk-chunk dokumen yang memiliki kemiripan tertinggi dengan vektor pertanyaan menggunakan cosine similarity

Chunk-chunk terpilih kemudian dijadikan konteks untuk LLM, dan LLM menghasilkan jawaban berdasarkan konteks tersebut. Parameter penting dalam RAG meliputi `CHUNK_SIZE` yang menentukan ukuran potongan teks, `TOP_K_INITIAL` yang menentukan berapa banyak kandidat awal yang diambil, `FINAL_TOP_M` yang menentukan berapa chunk yang dikirim ke LLM, `USE_RERANKER` yang mengaktifkan model reranking untuk meningkatkan presisi, dan `TEMPERATURE` yang mengontrol kreativitas jawaban LLM. Keunggulan RAG dibandingkan fine-tuning model adalah: RAG tidak memerlukan pelatihan ulang model, lebih mudah diperbarui dengan data baru, memberikan transparansi sumber informasi, dan lebih hemat biaya komputasi. RAG sangat berguna untuk aplikasi QA (Question Answering) berbasis dokumen perusahaan, chatbot layanan pelanggan, dan sistem pencarian informasi teknis. Model embedding yang umum digunakan dalam RAG antara lain sentence-transformers, OpenAI text-embedding-ada-002, dan multilingual-e5. Untuk reranking, biasanya digunakan Cross-Encoder model yang mengevaluasi relevansi pasangan query-dokumen secara lebih akurat dibandingkan Bi-Encoder biasa. Evaluasi sistem RAG dapat dilakukan menggunakan metrik seperti Faithfulness (seberapa akurat jawaban berdasarkan konteks), Answer Relevancy (seberapa relevan jawaban dengan pertanyaan), Context Precision (presisi konteks yang diambil), dan Context Recall (kelengkapan konteks yang diambil).